Как VLM воспринимает неоднозначные изображения

Qwen2.5-VL-3B-Instruct • Google Colab / Tesla T4 • только нейтральные запросы

6
изображений AmbiBench

24
случая в четырёх режимах

48
реальных обращений к модели

12 / 24
без технической ошибки

Технический статус

Число случаев; каждый режим проверялся на 6 картинках

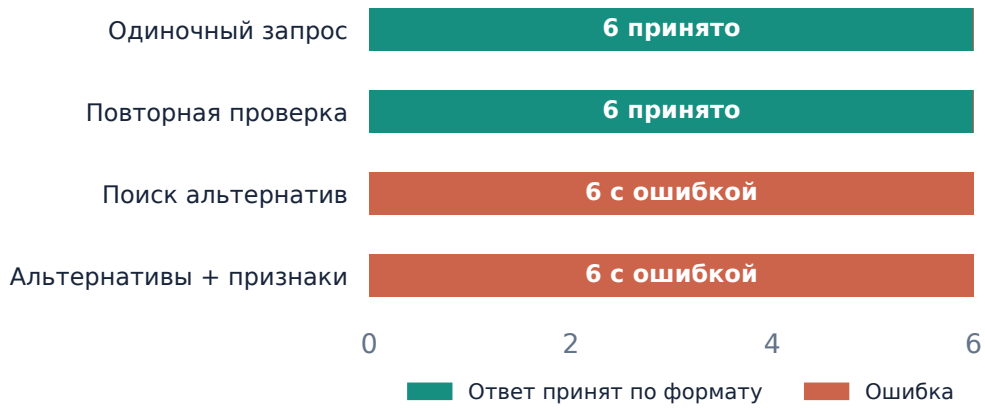

Стоимость в обращениях

Фактические вызовы / план при прохождении всех шагов

Меньше вызовов в двух режимах — следствие остановки с ошибкой.

Сводная таблица

Режим	Случаев	Принято	Ошибок	Принято, %	Вызовов	Время, с
Одиночный запрос	6	6	0	100%	6	60,9
Повторная проверка	6	6	0	100%	18	184,7
Поиск альтернатив	6	0	6	0%	12	153,7
Альтернативы + признаки	6	0	6	0%	12	151,7

Принято = ответ прошёл проверку формата. Время — сумма обращений, без загрузки весов.

НАБЛЮДЕНИЕ · 6/6 ответов совпали после повторной проверки

Все 12 ошибок: на шаге поиска альтернатив получено 5–6 гипотез при лимите 4.

Далее: проверить уточнённую инструкцию, сверить эталоны и выполнить независимую разметку.

Это отладочный пилот. Точность распознавания и преимущество агента пока не установлены.

Источник: bica_real_pilot_results.zip / pilot_v1 • 6 изображений • код и промпты зафиксированы в журнале